



南京農業大學

NANJING AGRICULTURAL UNIVERSITY

基于大语言模型的 典籍翻译学习一体化平台

目录

一 市场需求

二 技术路线

三 功能评测

四 应用场景

市场需求

壹



习近平总书记强调：
古籍是中华优秀传统文化的**重要载体**



ChatGPT爆火后，国内**大语言模型**也如雨后春笋般涌现

如何利用**AI**推动古籍挖掘？



针对中小學生：
复杂文言文试题
丧失学习兴趣

如何让古文学习过程
更加生动有趣？



针对公众：
想用诗意语言分享见闻感受
可文言文功底有限

有什么方法可以实现？



针对外国友人：
想学习古代中华文化
存在语言障碍

什么工具最方便使用？

壹

市场需求

基于大语言模型
的典籍翻译学习一体化平台



痛点一

功能不全面

壹

市场需求

百度

有道

谷歌

冬十一月甲午,礼部尚书袁炜为户部尚书兼武英殿大学士,预机务。

On the first day of the eleventh lunar month in winter, Yuan Wei, the Minister of Rites, was appointed as the Minister of Revenue and the Grand Academician of the Wuying Hall responsible for pre maintenance.



笔记

双语对照



通用场景

Winter November first afternoon, the Ministry of Rites book Yuan Wei for the Ministry of Ministry of the book and the Hall of Martial Valor Grand bachelor, pre-maintenance.

冬十一月甲午,礼部尚书袁炜为户部尚书兼武英殿大学士,预机务。

以上翻译结果来自有道神经网络翻译 (YNMT) · 通用场景

In November of the winter, Yuan Wei, the Ministry of Rites Shangshu, was a scholar of the Ministry of House and Wu Yingdian University.



基于大语言模型
的典籍翻译学习一体化平台

痛点二

翻译不准确




百度



有道



谷歌



痛点二

翻译不准确

玉带林中挂，金簪雪里埋。

这是唐代诗人白居易的《**钱塘湖春行**》中的名句，全诗描述了春天钱塘湖的美景。这句诗描绘了一幅美丽的画面：一条如玉带般的小河穿过林中，闪烁着光芒；而在雪地中，金簪被埋藏，形成鲜明对比。这两句诗用细腻的笔触展现了大自然的神奇和美丽。





痛点三

“幻觉”现象

技术路线

貳








ChatGLM2-6B

和其他
大模型相比




部署占用
GPU显存小

p-tuning v2
微调方法




使用少量参数
达到较好的
垂直领域微调效果

自回归填充
预训练机制



适合完成翻译任务



阿里团队开发国产开源大模型

可扩展性更好

使用Qwen训练“荀子”大语言模型
实现互动问答功能

貳

技术路线

数据处理

基于大语言模型
的典籍翻译学习一体化平台

一

数据预处理

二

调整数据标注规范

三

选择合格句作为训练语料

四

数据增强

五

搜集用户反馈内容
再标注、再训练

六

优化翻译效果

技术路线

数据选择

基于大语言模型
的典籍翻译学习一体化平台

古文-英文：《三国演义》
《资治通鉴》全书
古代官职（词级别）

古文-白话文：《二十四史》
《资治通鉴》全书

融合不同时期语料数据：

时期	具体时间区间	包含的史书
上古	先秦至西汉结束	《史记》
中古	西汉至唐开端	《汉书》《后汉书》《三国志》等
近古	唐以后	《宋史》《辽史》《金史》《元史》《明史》等



技术路线

爬取古文数据 生成pdf格式文件



OCR识别 转为word文档



人工对齐处理语料



转换为JSON格式


数据准备

基于大语言模型 的典籍翻译学习一体化平台

"chinese": "玄德曰：「南面而坐欲害卿，故不得不殺之。」，"english": "Then Xuande said to them, \"Cao Cao's imperial inspector, Che Zhou, tried to kill me, so I was forced to do it.\""},
 ("chinese": "丞相疑偏袒，遣二將軍候來問事。”，"english": "His Excellency wrongly suspected me of rebellion, and he sent you to make me answer for it."），
 ("chinese": "關公連日大恩，正思報效。安敢反邪？二將軍見言，備極分訴，備之幸也。”謝絕。王忠曰：「深蒙丞相不殺之恩，當於丞相處方便，以草兩家小程便耳。」”，"english": "But at that moment another rider appeared, shouting, \"You can't abuse them like this!\""},
 ("chinese": "玄德聞罷，””，"english": "Xuande expressed his thanks."），
 ("chinese": "次日曹操原路回馬，送出城外。”，"english": "The following day Xuande returned the two commanders' men and horses and escorted them out of the city."），
 ("chinese": "到後，王忠行不上十餘里，一雙驍盡，張飛躍路大喝曰：「我軍何必走分轍！你自說將如何又放了？」”說畢勒住。王忠在馬上發誓曰：「我已在馬上發願。」”，"english": "They had traveled some ten li"},
 ("chinese": "張飛怒聲喝退趕車，背推一人飛馬大叫：「不得就護！」視之，乃雲長也。”，"english": "But at that moment another rider appeared, shouting, \"You can't abuse them like this!\""},
 ("chinese": "到後，王忠方纔放心。”，"english": "Dai and Zhong knew they were saved, wilder brother has released them."），
 ("chinese": "雲長曰：「昨日某放了，甚的如何不遵法令？」飛曰：「今番放了，下次又来。」雲長曰：「待他再來，殺之未遲。」到後，王忠謹告退曰：「便與相送我三弟，也不來了。」”，"english": "I have already let him go yesterday, how dare you disobey my orders?\""},
 ("chinese": "望將軍寬恕。”飛曰：「便是曹賊白來，也殺地并甲不回！今權借目害下寨加罪！」”，"english": "We beg forgiveness. \\\Even if Cao Cao himself comes here,\\\ Zhang Fei will kill him and all his soldiers without mercy! Today we are punishing you for harboring enemies!"），
 ("chinese": "到後，王忠方纔放心而去。”，"english": "The commanders scurried off, grateful to be spared."），
 ("chinese": "雲長、關公同兒女操曰：「曹操必然死矣。」孫乾謂玄德曰：「徐州避難之地，不可久居；不若分兵屯小沛，守徐州，為後應之計，以防曹操。」玄德用其言，令雲長守下邳，甘、糜二夫人隨後而往。”，"english": "Zhang Fei and Guan Gong went to Xiaopei."），
 ("chinese": "王忠拜辭曹操，具奏曹操不反之事。”，"english": "In the capital Liu Dai and Wang Zhong defended Xuande's conduct to Cao Cao. But the prime minister"},
 ("chinese": "操既喜：「解隨之徒，何須用刑！」喝令左右都出斬之。”，"english": "Why should I spare you? Cao ordered them to be marched out and executed."），
 ("chinese": "正是：””，"english": "Indeed:"），
 ("chinese": "犬豕何堪共浴門，魚龍空自向潭中。”，"english": "Can dogs and pigs with tigers share the field? Can shrimp and fish with dragons vie below the waves?"），
 ("chinese": "皇帝，””，"english": "Emperor"}
 ("chinese": "太上皇帝，””，"english": "Emperor Emeritus")
 ("chinese": "太上皇，””，"english": "Emperor Emeritus")
 ("chinese": "監國，””，"english": "Regent")
 ("chinese": "皇后，””，"english": "Empress")
 ("chinese": "太皇太后，””，"english": "Grand Empress Dowager")
 ("chinese": "皇太后，””，"english": "Empress Dowager")
 ("chinese": "太后，””，"english": "Empress Dowager")
 ("chinese": "太皇妃，””，"english": "Grand Consort Dowager")
 ("chinese": "皇妃，””，"english": "Consort Dowager")
 ("chinese": "皇貴妃，””，"english": "Imperial Honored Consort")
 ("chinese": "貴妃，””，"english": "Honored Consort")
 ("chinese": "嬪妃，””，"english": "Concubine")

[illegible]

- 融合词、句、段三个级别平行语料
- 采用回译技术



技术路线

平行语料数据

按比例分为

训练集和验证集

模型训练

基于大语言模型
的典籍翻译学习一体化平台

```
model_path_check = "E:\\4C\\ChatGLM2-6B\\output_model\\test_m2c-128-2e-2\\checkpoint-1000"
prefix_state_dict = torch.load(os.path.join(model_path_check, "pytorch_model.bin"))
new_prefix_state_dict = {}
for k, v in prefix_state_dict.items():
    if k.startswith("transformer.prefix_encoder."):
        new_prefix_state_dict[k[len("transformer.prefix_encoder."):]] = v
model.transformer.prefix_encoder.load_state_dict(new_prefix_state_dict)
2 usages
def trans_m_c(input_text, response, history):
    global tokenizer, config, model, prefix_state_dict, new_prefix_state_dict
    # print(f"{model_path_check}:\n")
    response, history = model.chat(tokenizer, input_text, history=[])
    print(input_text + ", " + response)
    return response, history
```

```
train.sh
1 PRE_SEQ_LEN=128
2 LR=2e-2
3 NUM_GPUS=1
4
5 torchrun --standalone --nnodes=1 --nproc-per-node=$NUM_GPUS main.py \
6 --do_train \
7 --train_file /home/pgrad/XiaoHanJing/2024/4C/dataprocessing/final_cm.json \
8 --validation_file /home/pgrad/XiaoHanJing/2024/4C/dataprocessing/valid_cm.json \
9 --preprocessing_num_workers 10 \
10 --prompt_column m \
11 --response_column c \
12 --overwrite_cache \
13 --model_name_or_path /home/pgrad/XiaoHanJing/2024/4C/chatglm2_6b/chatglm2-6b/ \
14 --output_dir output/test_m2c-$PRE_SEQ_LEN-$LR \
15 --overwrite_output_dir \
16 --max_source_length 64 \
17 --max_target_length 128 \
18 --per_device_train_batch_size 1 \
19 --per_device_eval_batch_size 1 \
20 --gradient_accumulation_steps 16 \
21 --predict_with_generate \
22 --max_steps 3000 \
23 --logging_steps 10 \
24 --save_steps 1000 \
25 --learning_rate $LR \
26 --pre_seq_len $PRE_SEQ_LEN \
27 # --quantization_bit 4
28
29 #CUDA_VISIBLE_DEVICES=
```

使用p-tuning v2方法

微调


ChatGLM

“荀子”大语言模型——基于Qwen

因果语言模型预训练

多任务指令微调

人类反馈强化学习



检索增强生成 (RAG)

为缓解大语言模型
“幻觉”现象



搜集古文常识
使用llama_index方法
构建本地知识库




“荀子”大模型根据
知识库生成内容

搜集文学常识



知识库



结合

“荀子”

功能评测

叁



叁

功能评测

翻译功能



基于大语言模型
的典籍翻译学习一体化平台

古-白
白-古
古-英



用户反馈

翻译结果评估

模型	BLEU
Transformer(baseline)	0.8901
百度翻译(topline)	12.3526
谷歌翻译(topline)	10.7757
本模型（古文-英文）	12.2093

模型	BLEU
Transformer(baseline)	8.9554
百度翻译(topline)	24.9731
本模型（古文-白话文）	22.7322

模型	BLEU
古文-英文	12.2093
古文-白话文	22.7322
白话文-古文	21.7878

使用Evahan2023国际古汉语翻译竞赛的测试集数据进行测试

```
# Metric
def compute_metrics(eval_preds):
    preds, labels = eval_preds
    if isinstance(preds, tuple):
        preds = preds[0]
    decoded_preds = tokenizer.batch_decode(preds, skip_special_tokens=True)
    if data_args.ignore_pad_token_for_loss:
        # Replace -100 in the labels as we can't decode them.
        labels = np.where(labels != -100, labels, tokenizer.pad_token_id)
    decoded_labels = tokenizer.batch_decode(labels, skip_special_tokens=True)

    score_dict = {
        "rouge-1": [],
        "rouge-2": [],
        "rouge-l": [],
        "bleu-4": []
    }

    for pred, label in zip(decoded_preds, decoded_labels):
        hypothesis = list(jieba.cut(pred))
        reference = list(jieba.cut(label))
        rouge = Rouge()
        scores = rouge.get_scores(' '.join(hypothesis), ' '.join(reference))
        result = scores[0]


        for k, v in result.items():
            score_dict[k].append(round(v["F"] * 100, 4))
        bleu_score = sentence_bleu([list(label)], list(pred), smoothing_function=
            SmoothingFunction().method3)
        score_dict["bleu-4"].append(round(bleu_score * 100, 4))

    for k, v in score_dict.items():
        score_dict[k] = float(np.mean(v))
    return score_dict
```

叁

功能评测

智能问答功能



基于大语言模型
的典籍翻译学习一体化平台

荀子大语言模型



互动对话模式

“荀子”模型优势

模型名称	文本翻译		文本匹配			文本分类			分词			命名实体识别		
	BLEU-4	rouge-l	P	R	F	P	R	F	P	R	F	P	R	F
Qwen-7B	27.36	50.17	98.09	98.07	98.07	72.92	71.68	71.85	91.85	92.3	92.08	82.69	80.21	81.4
Xunzi-Qwen-300steps	27.41	50.01	98.67	98.65	98.65	81.7	79.57	80.29	92.49	93.09	92.79	84.13	82.53	83.3
Xunzi-Qwen	28.19	50.76	98.87	98.84	98.84	81.42	79.21	79.88	92.81	93.48	93.14	84.7	82.88	83.78
Atom-7B	22.92	45.39	96.8	96.71	96.71	72.19	70.97	70.81	90.64	91.41	91.03	81.12	77.64	79.28
Baichuan-7B	25.39	48.05	98.27	98.26	98.26	73.35	71.33	71.74	91.7	92.39	92.04	81.85	78.9	80.3
InternLM-7B	26.59	48.87	95.03	94.97	94.97	72.77	72.04	72.14	91.53	91.58	91.55	81.76	78.59	80.11

古文理解能力优势明显

高质量完成
古文处理任务

叁

功能评测

辅助功能



基于大语言模型
的典籍翻译学习一体化平台

书城展示



用户登录



古籍推荐




发布评论

主观结果评估

招募81位用户
包括中小學生、成年人、外国交换生
多数人给出了满意及以上的评价。

用户满意度




序号	来源	来自你的身满意程度	评价 (选填)
45	## 6	线下 N/A 122. 外国人非常满意	AMAZING! As a beginner in studying classical Chinese, this software has been a
38	## 7	线下直 112. 外国人非常满意	I appreciate the speed of translation and the reliability of the results. It's a valuable
7	## 5	线下直 112. 外国人满意	I encountered some inaccuracies in the translations, especially with more comple
16	## 5	线下直 36.1 外国人非常满意	It would be great to see additional learning features integrated into the software, s
10	## 7	微信 N/A 180. 成年人非常满意	翻译结果准确，而且界面设计简洁，很容易上手。
15	## 8	微信 N/A 221. 中小学非常满意	非常非常非常好
17	## 4	手机直 112. 成年人非常满意	感谢这款程序，让我能够更深入地理解古代书籍，对学习文言文有很大帮助。
1	## 2	微信 N/A 122. 中小学非常满意	好
2	## 7	微信 N/A 223. 中小学非常满意	好
3	## 3	微信 N/A 39.1 中小学非常满意	好
4	## 7	微信 N/A 117. 中小学非常满意	好
5	## 1	微信 N/A 39.1 中小学非常满意	好
6	## 4	微信 N/A 39.1 成年人满意	好
8	## 3	手机直 112. 成年人满意	很好
9	## 1	线下 N/A 112. 外国人满意	很好
13	## 9	微信 N/A 111. 成年人满意	很好
24	## 3	手机直 223. 中小学非常满意	适合使用的一款学习工具
14	## 7	微信 N/A 175. 成年人满意	挺好
12	## 4	微信 N/A 42.8 成年人非常满意	喜欢这样的创意，把翻译和古籍推荐结合，这样可以更轻松地看古书了。
30	## 6	微信 N/A 182. 中小学非常满意	这款程序让我对我的古文重拾信心了，希望我可以利用取得更好的考试成绩

应用场景

肆





荀子大语言模型
对话互动功能
增强古文学习趣味性



古-白、白-古翻译功能
将古文轻松
融入日常生活



古-英翻译功能
助力古籍文化
国际传播



南京农业大学

NANJING AGRICULTURAL UNIVERSITY

恳请评委老师批评指正！

